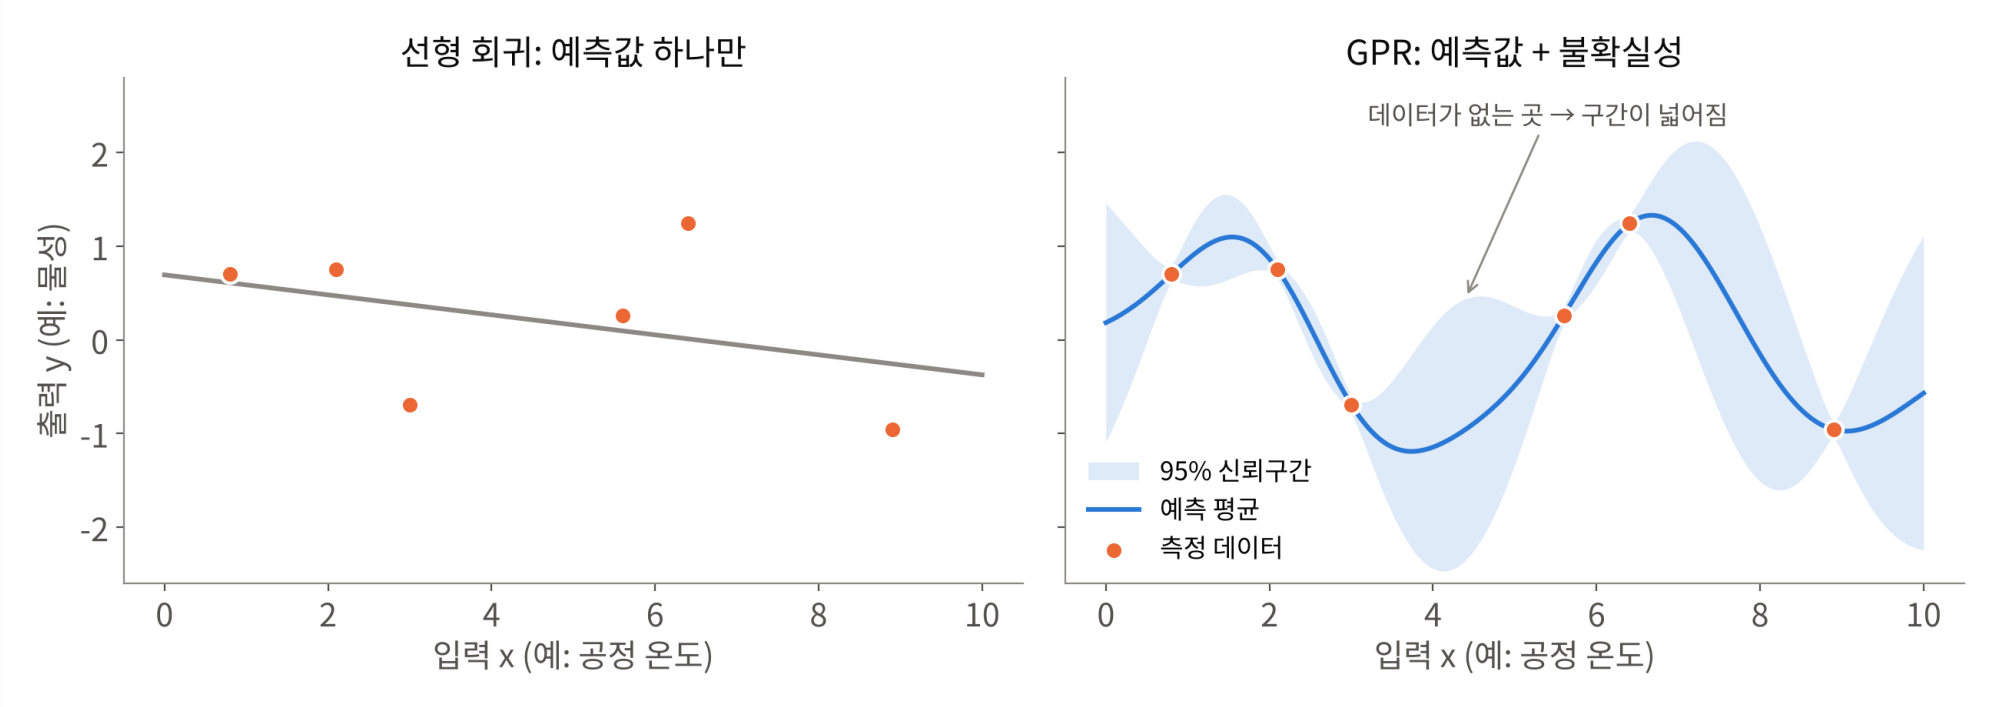
머신러닝 기초

가우시안 과정 회귀
Gaussian Process Regression

데이터가 적을 때, 예측과 함께 “얼마나 확신하는지”까지 말해 주는 회귀

실험 데이터가 적을 때, 무엇을 믿어야 할까?



GPR은 **예측값**과 함께 **그 예측을 얼마나 믿어도 되는지(불확실성)**를 함께 알려 준다.

가장 작은 예제: 새로운 x* = 2.5 또는 6.0의 y는?

x	y
1	1.0
2	1.8
3	3.5
2.5	**?**
6.0	**?**

기존 관측 3개 + 새 입력 x*

1 **관측 구간 안 (1 ≤ x ≤ 3)**

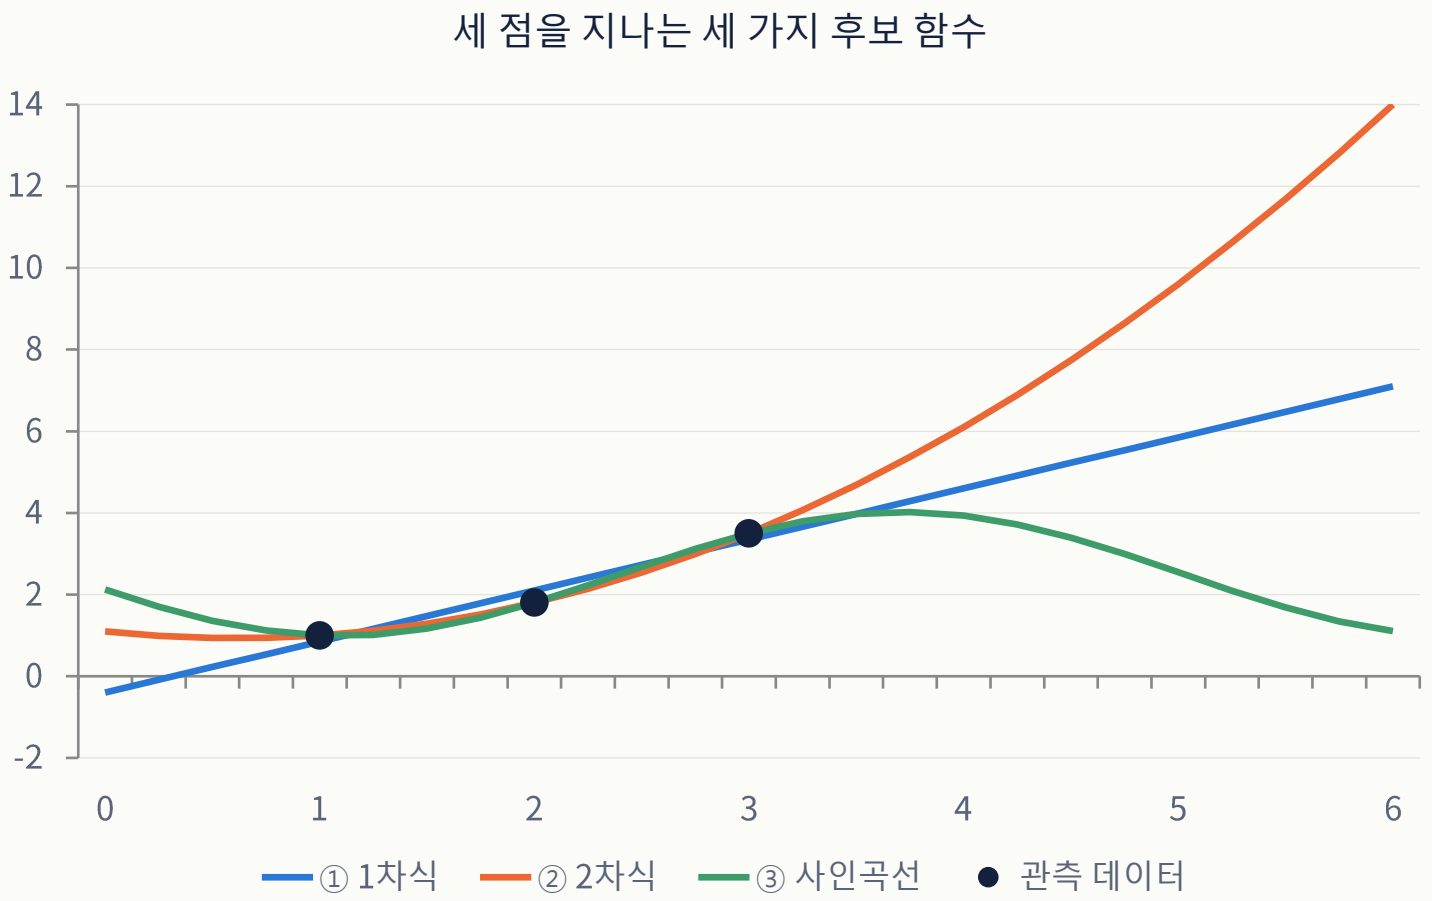
어떤 함수를 가정해도 예측 y가 비슷한 범위에 나타남 → 불확실성 작음

2 **관측 구간 밖 (x < 1, x > 3)**

가정한 함수마다 예측이 크게 갈림 → 불확실성 커짐

GPR은 하나의 값이 아니라 **평균 μ와 분산 σ^2**를 동시에 제시

같은 데이터, 서로 다른 함수



x = 1 ~ 3 구간

세 함수 모두 관측점 근처를 지남 → 예측이 비슷, 불확실성 작음

x > 3 구간

함수마다 예측이 크게 갈림 → GPR은 이 퍼짐을 σ^2로 표현

발상의 전환: 파라미터가 아니라 '함수'에 확률을 준다

기존 (모수적) 회귀

$y = w_0 + w_1 x + w_2 x^2 + \cdots$

- 함수의 모양을 먼저 가정 (직선, 2차식…)
- 데이터로 몇 개의 계수 w를 맞춘다
- 가정이 틀리면 데이터가 많아도 틀린다

가우시안 과정 회귀

f ~ "가능한 함수들의 분포"

- 모양 대신 "부드러움" 정도만 가정
- 데이터와 맞지 않는 함수를 걸러낸다
- 남은 함수들의 평균 = 예측, 퍼짐 = 불확실성

가우시안 과정이란?

정의 — 임의의 유한 개 입력 $x_1, \cdots, x_n$에서의 함수값 $(f(x_1), \cdots, f(x_n))$이 **항상 다변량 정규분포를 따르는** 확률 과정

$$f(x) \sim \mathcal{GP}(\, m(x), k(x, x')\,)$$

평균 함수 m(x)

데이터를 보기 전 기대하는 값. 보통 **0**(또는 상수)으로 두고 데이터에 맡긴다.

공분산 함수 (커널) k(x, x′)

두 입력에서의 함수값이 **얼마나 함께 움직이는지**. GPR의 성격을 사실상 전부 결정한다.

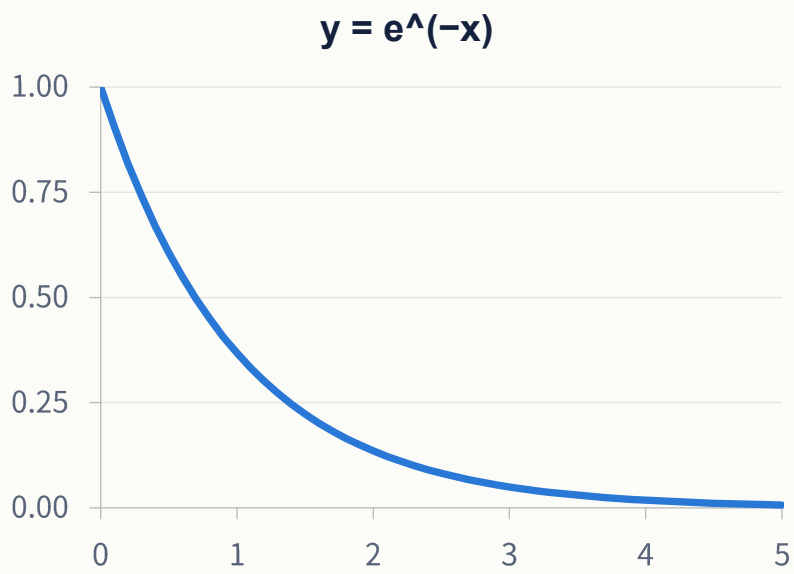
→ “무한 차원 정규분포”: 정규분포가 **숫자**를 뽑는다면, GP는 **함수 하나**를 통째로 뽑는다.

재료 ②: 커널 = “가까운 입력은 비슷한 출력”

$$k(x, x') = \sigma_f^2 \cdot \exp\left(-(x - x')^2 / 2\ell^2 \right)$$

가장 널리 쓰이는 RBF(Radial Basis Function) 커널 : 각 x값들끼리의 유사도

기호	이름	의미
$x \approx x'$	가까운 두 점	$k \approx \sigma_f^2$ → 상관 큼, 값이 거의 같다
$x \gg x'$ 거리	먼 두 점	$k \to 0$ → 서로 거의 무관
ℓ	길이 척도	“얼마나 떨어져야 남남이 되나” — 함수의 굴곡 폭
σ_f	신호 크기	함수값이 0에서 얼마나 크게 벗어나는가



x 자리에 $(x - x')^2 / 2\ell^2$가 들어간다
→ 두 점이 같으면 1, 멀어질수록 0으로 떨어진다

예측 = 이미 측정된 y값에 근거해 적절한 함수만 남긴다.. $f^*(\mu^*, \sigma^{*2})$

학습 데이터 (X, y)와 새 입력 x*를 하나의 정규분포로 묶고, 앞의 조건부 공식을 적용

예측평균 $\mu^* = k^{*T} (K + \sigma_n^2 I)^{-1} y$

예측분산 $\sigma^{*2} = k(x^*, x^*) - k^{*T} (K + \sigma_n^2 I)^{-1} k^*$

K: 학습점끼리의 커널 행렬 (n×n), k*: 새 입력 x*와 각 학습점 사이의 커널 벡터, σ_n^2: 측정 노이즈, I: 단위 행렬

평균 읽는 법

$\mu^* = \Sigma\, \alpha_i\, k(x^*, x_i)$ … ($\Sigma\, \alpha_i = (K + \sigma_n^2 I)^{-1} y$ 로 두고 미리 계산)
— **가까운 학습점일수록 큰 가중치**를 받는 가중합

분산 읽는 법

(사전 분산) − (데이터가 설명해 준 양) → **데이터 근처에서만 줄어든다**

다음 장에서 세 점 예제로 두 식을 하나씩 뜯어 본다 (편의상 $K + \sigma_n^2 I$를 K로 표기)

수치로 확인하기 ($\ell = 1, \sigma_f = 2, \sigma_n = 0.1$)

$x^* = 2.5$ (관측 구간 안)

평균 μ^*

2.79

표준편차 σ^*

0.28

x = 2, 3과 유사도가 높아 정보량이 큼 → 좁은 신뢰구간 (약 2.79 ± 0.56)

$x^* = 6$ (관측 구간 밖)

평균 μ^*

0.05

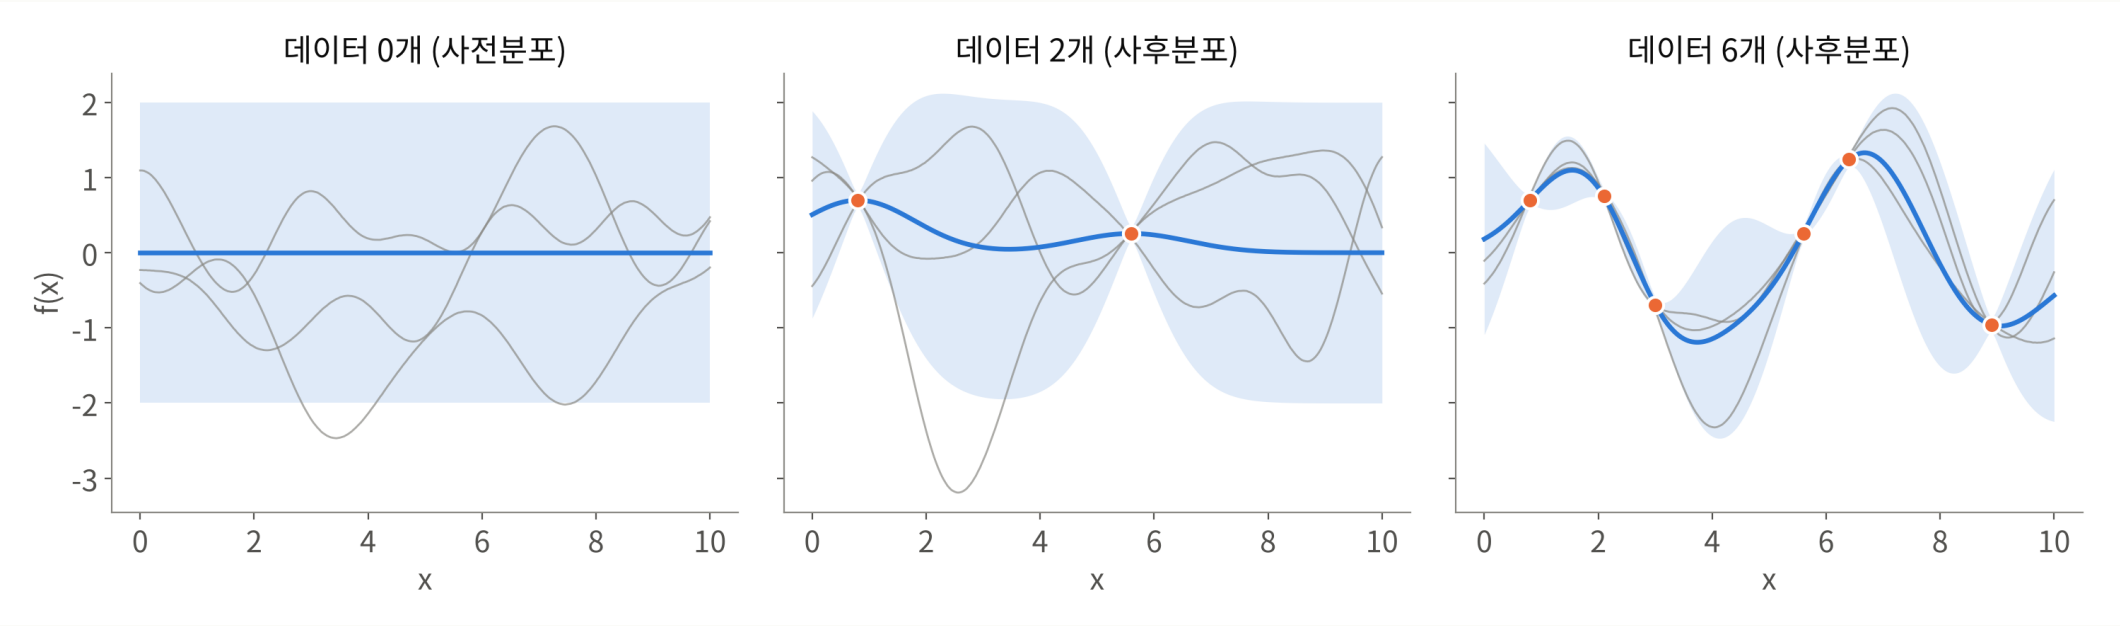
표준편차 σ^*

2.00

모든 관측과 유사도 ≈ 0 → $\sigma^* \approx \sigma_f = 2$, 평균은 사전 평균 0 으로 복귀

하이퍼파라미터는 설명용으로 고정한 값이며, 실제로는 3장의 주변 우도 최대화로 정한다.

데이터가 쌓일수록 가능한 함수가 좁혀진다



파란 선 예측 평균 · **파란 띠** 95% 구간 (μ ± 2σ) · **회색 선** 사후분포에서 뽑은 함수 샘플

데이터 점에서는 띠가 거의 0 — 사이 구간에서는 다시 벌어진다

학습 절차: 주변 우도를 최대화하는 반복

1 초기값 설정

θ = { ℓ, σf, σn }에 초기값 부여
(ℓ은 feature 개수만큼 존재)

2 K 계산

초기값으로 K를 만들고
log p(y | X, θ) 계산

3 반복 업데이트

∂L/∂ℓ, ∂L/∂σf, ∂L/∂σn으로
L이 최대가 되도록 갱신

$$L = \log p(y \mid X, \theta) = -\tfrac{1}{2}\, y^{T} K^{-1} y - \tfrac{1}{2} \log|K| - (n/2) \log 2\pi$$

경사 기반으로 L을 최대화 (오차 역전파처럼 기울기를 따라 반복 갱신) · 세 항의 의미는 부록 참고

학습은 새 y를 만드는 과정이 아니라, 기존 실험값으로 θ를 정하는 과정. θ가 정해지면 새 x*의 μ*, σ^{*2}를 계산한다.

언제 GPR을 쓰고, 언제 피할까?

강점

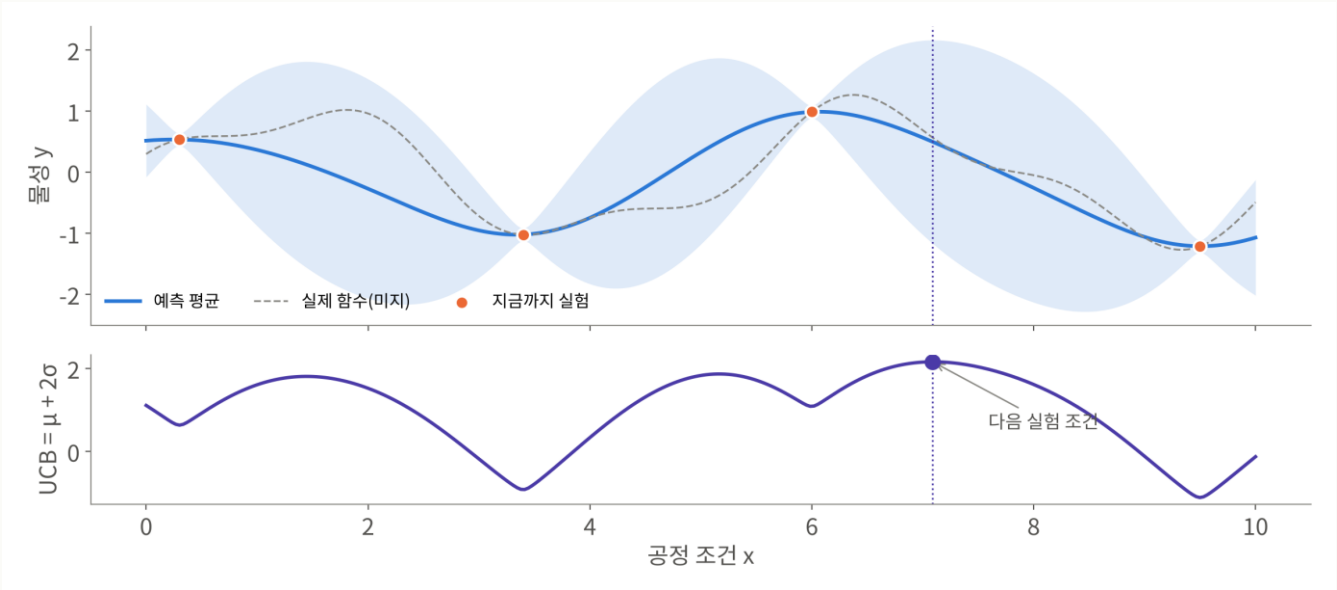
- 소량 데이터(수십~수백 개)에서도 안정적
- 예측마다 불확실성이 함께 나온다
- 하이퍼파라미터가 적고 의미가 해석 가능
- 커널로 사전지식(매끄러움, 주기성)을 주입

약점

- 계산량 $O(n^3)$ — 데이터 수천 개 이상이면 부담
- 입력 차원이 높으면(수십 차원↑) 성능 저하
- 커널 선택이 결과를 좌우
- 기본형은 노이즈를 정규분포로 가정

대규모 데이터에는 희소(sparse) GP, 근사 기법 또는 신경망과의 결합으로 확장한다.

대표 응용: 베이지안 최적화로 다음 실험 고르기

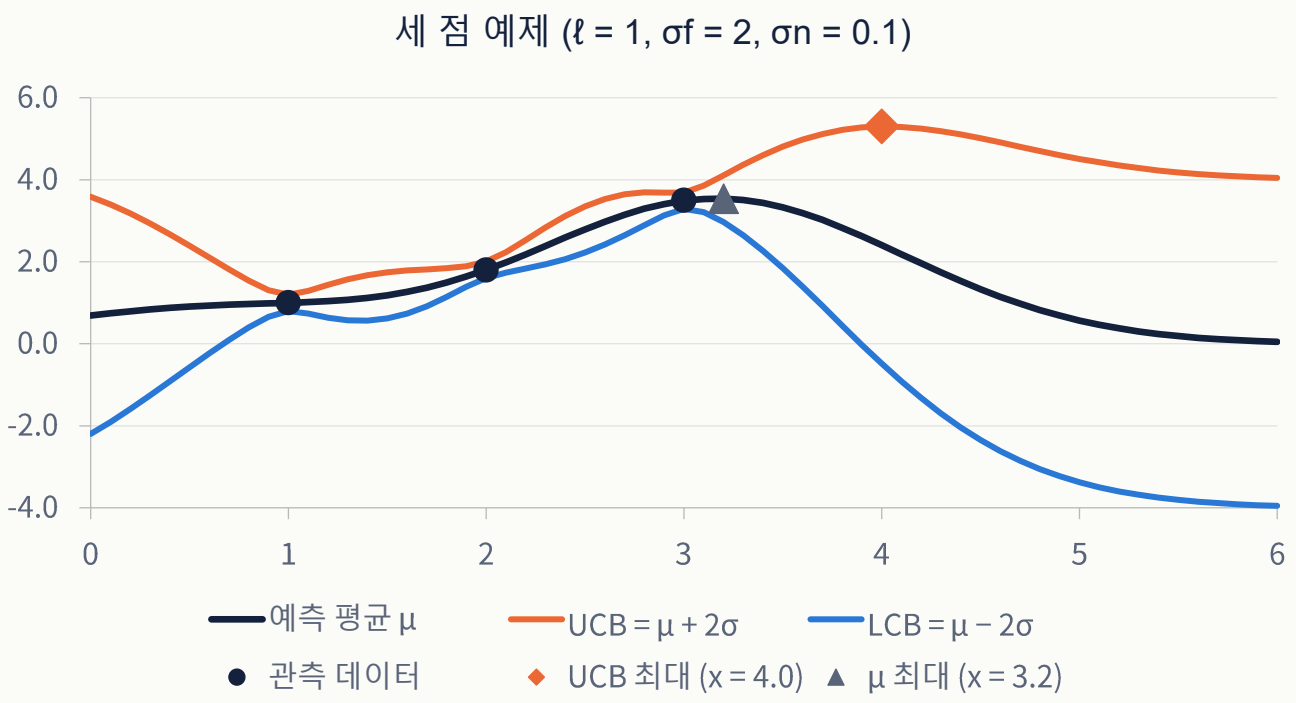


1. **학습** 지금까지의 실험으로 GPR
2. **획득 함수** UCB = μ + 2σ
   “좋아 보이는 곳 + 잘 모르는 곳”
3. **실험** UCB 최대 지점을 측정
4. **반복** 데이터 추가 → ①로

예: 신소재 조성, 염색·공정 조건, 촉매 탐색, 신경망 하이퍼파라미터 튜닝 — 적은 실험 횟수로 최적점에 접근

UCB / LCB: 평균에 불확실성을 더하거나 빼기

$$UCB(x) = \mu(x) + \kappa\,\sigma(x) \qquad LCB(x) = \mu(x) - \kappa\,\sigma(x)$$



UCB → 최대화 문제

물성·수율처럼 클수록 좋을 때
UCB가 가장 큰 x에서 다음 실험

LCB → 최소화 문제

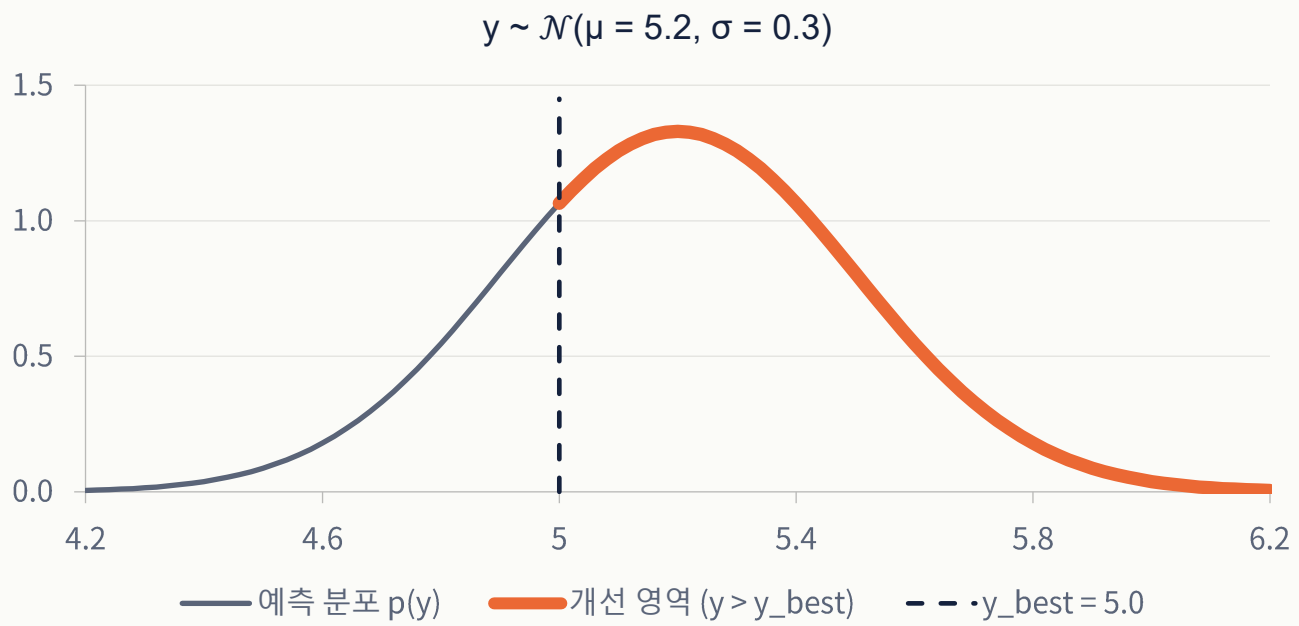
오차·비용처럼 작을수록 좋을 때
LCB가 가장 작은 x에서 다음 실험

κ = 탐색 vs 활용 조절

κ ↑ 모르는 곳 탐색 · κ ↓ 좋아 보이는 곳 활용
κ = 2 ≈ 95% 구간의 끝

EI (Expected Improvement): 기대 개선량

$$EI(x) = \int_{y_best}^{\infty} (y - y_best) \cdot p(y)\, dy = E[\max(y - y_best, 0)]$$
$$= (\mu - y_best)\,\Phi(z) + \sigma\,\phi(z), \quad z = (\mu - y_best) / \sigma$$



개선량 (y − y_best)
y_best보다 얼마나 더 좋은가

확률 p(y) dy
그 값이 나올 가능성

y_best ~ ∞ 구간만 합산
개선이 없는 결과는 0으로 처리

Φ, ϕ
표준정규분포의 누적분포 · 밀도

EI 계산 예: y_best = 5.0, μ = 5.2, σ = 0.3

① 평균 개선량	Δ = μ − y_best = 5.2 − 5.0	0.2
② 표준화	z = Δ / σ = 0.2 / 0.3	0.667
③ 개선 확률	Φ(z) = P(y > y_best)	0.748
④ 표준정규 밀도	ϕ(z) = z에서의 높이	0.319

Φ(z) = 0.748 → 이 후보가 y_best를 넘어설 확률 약 74.8%

$$EI = \Delta \cdot \Phi(z) + \sigma \cdot \phi(z)$$

$$= 0.2 \times 0.748 + 0.3 \times 0.319$$

$$\approx 0.245$$

개선량 × 개선 확률

Δ · Φ(z)

0.150

불확실성이 주는 기회

σ · ϕ(z)

0.096

수치 적분 · 몬테카를로 시뮬레이션으로도 0.245 확인

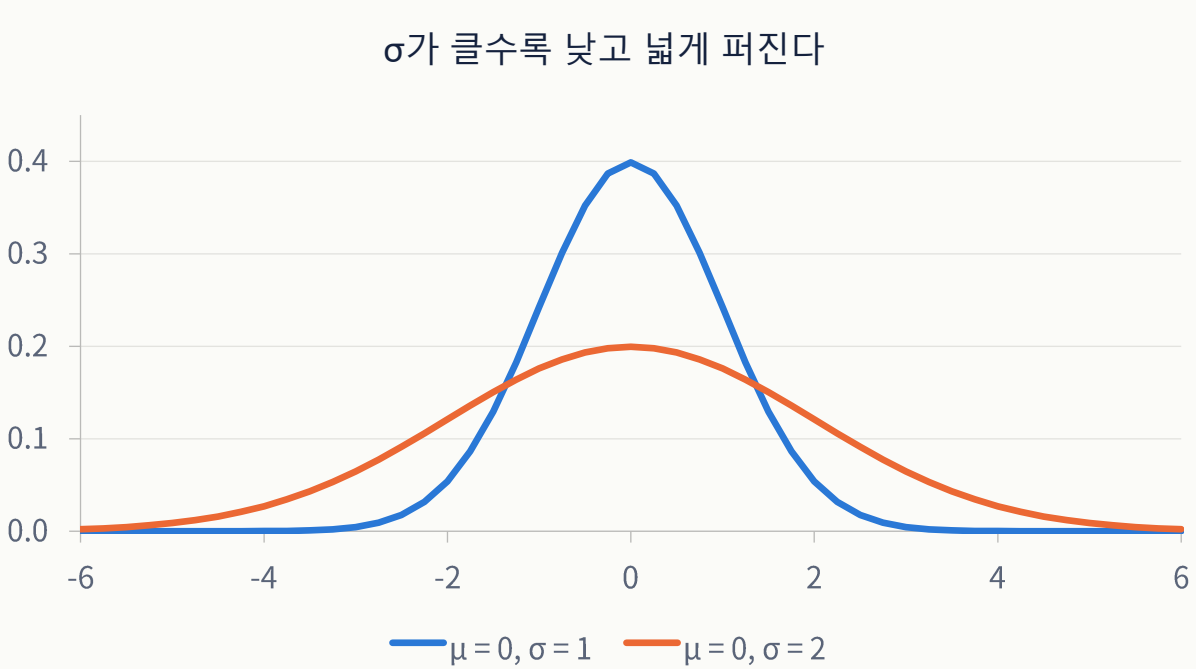
4 · 정리

오늘의 세 문장

1. GPR은 하나의 함수가 아니라 **함수들의 분포**를 다룬다.
2. **커널**이 “가까우면 닮는다”를 정의하고, 예측은 정규분포의 조건화로 계산된다.
3. 예측과 함께 나오는 **불확실성** 덕분에 적은 실험으로 탐색하는 데 강하다.

정규분포 (가우시안 분포)

$$f(x) = 1 / (\sigma\sqrt{(2\pi)}) \cdot \exp(-(x-\mu)^2 / 2\sigma^2) \qquad X \sim \mathcal{N}(\mu, \sigma^2)$$



μ (평균) 분포의 중심 위치
σ (표준편차) 퍼진 정도 · σ^2은 분산
$1/(\sigma\sqrt{2\pi})$ 곡선 아래 넓이를 1로 맞추는 상수

68 – 95 – 99.7 규칙
μ ± 1σ: 68% · μ ± 2σ: 95% · μ ± 3σ: 99.7%

RBF(가우시안) 커널과 같은 모양
$\exp(-(x-x')^2/2\ell^2)$ — ℓ이 σ 역할