Random Forest

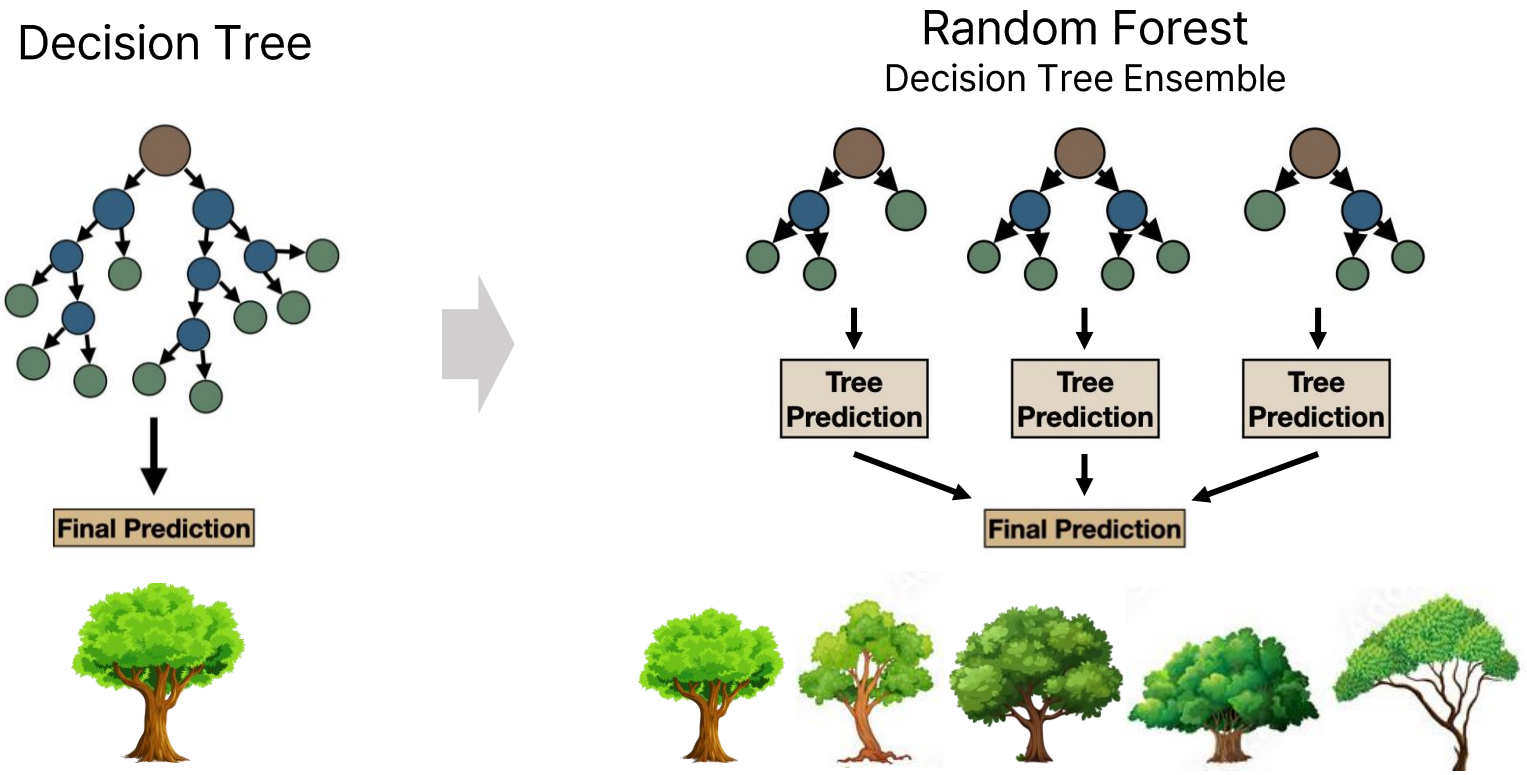
랜덤포레스트

Overview

Random Forest

랜덤 포레스트(Random Forest)는
의사결정나무(Decision Tree)를 **무작위(Random)**로 여러 개를 만들어
각각의 예측을 종합해 최종 결과를 내는 **앙상블(Ensemble) 학습 방법**.

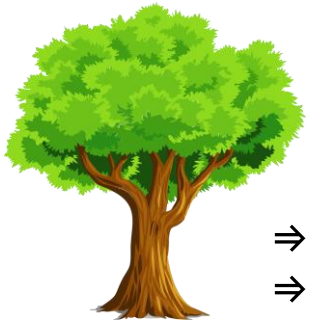
Decision Tree(의사결정나무)는
데이터를 기준에 따라 분할해 예측을 수행하는 트리 구조의 알고리즘.



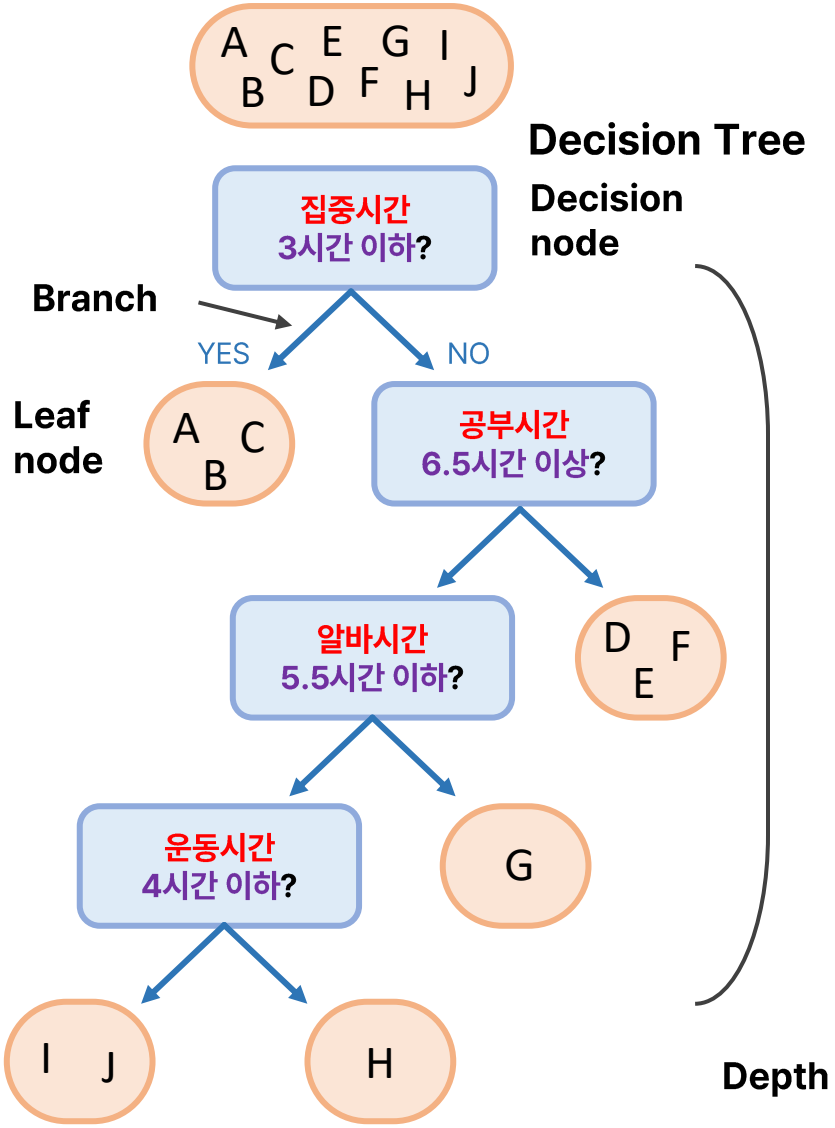
Decision Tree

Decision Tree는
질문을 반복하면서, 데이터를 계속 나누는 알고리즘

구분	공부시간	집중시간	운동시간	알바시간	성적
A	5	1	10	8	15
B	2	1	8	9	21
C	3	2	1	10	29
D	5	4	9	6	38
E	4	4	5	7	52
F	5	4	6	4	63
G	6	5	2	5	70
H	9	7	4	1	78
I	7	7	3	2	91
J	9	8	3	3	95
예측용	7	6	2	9	???

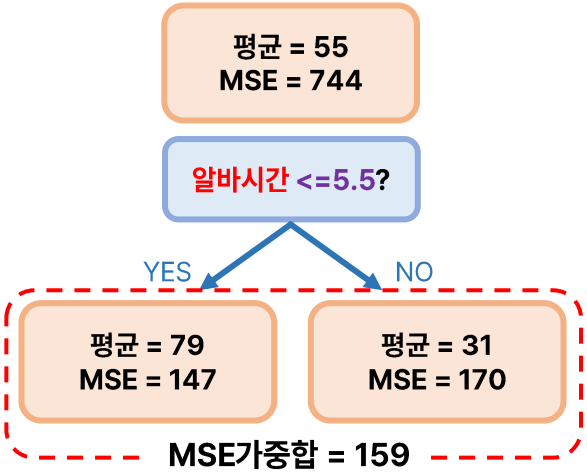


⇒ 분할 전/후 상태 비교는 어떻게?
⇒ 어떤 기준이 좋은 기준일까?



데이터 상태와 분할

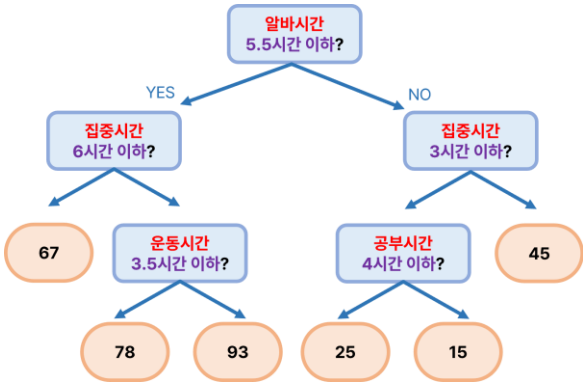
구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)
A	5	1	10	8	15		-40	1616	
B	2	1	8	9	21		-34	1170	
C	3	2	1	10	29		-26	686	
D	5	4	9	6	38		-17	296	
E	4	4	5	7	52	55	-3	10	744
F	5	4	6	4	63		8	61	
G	6	5	2	5	70		15	219	
H	9	7	4	1	78		23	520	
I	7	7	3	2	91		36	1282	
J	9	8	3	3	95		40	1584	



기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
알바시간 <=5.5	F	5	4	6	4	63		-16	269			
	G	6	5	2	5	70		-9	88			
	H	9	7	4	1	78	79	-1	2	147	0.5	
	I	7	7	3	2	91		12	135			
	J	9	8	3	3	95		16	243			
알바시간 >5.5	A	5	1	10	8	15		-16	256			159
	B	2	1	8	9	21		-10	100			
	C	3	2	1	10	29	31	-2	4	170	0.5	
	D	5	4	9	6	38		7	49			
	E	4	4	5	7	52		21	441			

⇒ 분할 전 MSE > 분할 후 MSE
⇒ 오차(MSE) 감소

구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)
A	5	1	10	8	15		-40	1616	
B	2	1	8	9	21		-34	1170	
C	3	2	1	10	29		-26	686	
D	5	4	9	6	38		-17	296	
E	4	4	5	7	52	55	-3	10	744
F	5	4	6	4	63		8	61	
G	6	5	2	5	70		15	219	
H	9	7	4	1	78		23	520	
I	7	7	3	2	91		36	1282	
J	9	8	3	3	95		40	1584	



기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
알바시간 <=5.5	F	5	4	6	4	63	79	-16	269	147	0.5	159
	G	6	5	2	5	70		-9	88			
	H	9	7	4	1	78		-1	2			
	I	7	7	3	2	91		12	135			
	J	9	8	3	3	95		16	243			
알바시간 >5.5	A	5	1	10	8	15	31	-16	256	170	0.5	
	B	2	1	8	9	21		-10	100			
	C	3	2	1	10	29		-2	4			
	D	5	4	9	6	38		7	49			
	E	4	4	5	7	52		21	441			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
집중시간 <=6	F	5	4	6	4	63	67	-4	12	12	0.4	36.5
	G	6	5	2	5	70		4	12			
집중시간 >6	H	9	7	4	1	78	88	-10	100	53	0.6	
	I	7	7	3	2	91		3	9			
	J	9	8	3	3	95		7	49			

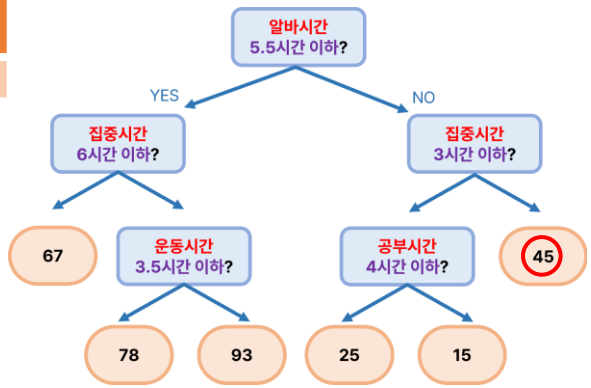
기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
운동시간 <=3.5	H	9	7	4	1	78	78	0	0	0	0.3	2.4
운동시간 <=3.5	I	7	7	3	2	91	93	-2	4	4	0.6	
	J	9	8	3	3	95		2	4			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
집중시간 <=3	A	5	1	10	8	15	22	-7	44	33	0.6	39
	B	2	1	8	9	21		-1	0			
	C	3	2	1	10	29		7	54			
집중시간 >3	D	5	4	9	6	38	45	-7	49	49	0.4	
	E	4	4	5	7	52		7	49			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
공부시간 <=4	B	2	1	8	9	21	25	-4	16	16	0.6	9.6
	C	3	2	1	10	29		4	16			
공부시간 >4	A	5	1	10	8	15	15	0	0	0	0.3	

구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)
A	5	1	10	8	15		-40	1616	
B	2	1	8	9	21		-34	1170	
C	3	2	1	10	29		-26	686	
D	5	4	9	6	38		-17	296	
E	4	4	5	7	52	55	-3	10	744
F	5	4	6	4	63		8	61	
G	6	5	2	5	70		15	219	
H	9	7	4	1	78		23	520	
I	7	7	3	2	91		36	1282	
J	9	8	3	3	95		40	1584	

구분	공부 시간	집중 시간	운동 시간	알바 시간	성적
예측용	7	6	2	9	45



기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
알바시간 <=5.5	F	5	4	6	4	63	79	-16	269	147	0.5	159
	G	6	5	2	5	70		-9	88			
	H	9	7	4	1	78		-1	2			
	I	7	7	3	2	91		12	135			
	J	9	8	3	3	95		16	243			
알바시간 >5.5	A	5	1	10	8	15	31	-16	256	170	0.5	
	B	2	1	8	9	21		-10	100			
	C	3	2	1	10	29		-2	4			
	D	5	4	9	6	38		7	49			
	E	4	4	5	7	52		21	441			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
집중시간 <=6	F	5	4	6	4	63	67	-4	12	12	0.4	36.5
	G	6	5	2	5	70		4	12			
집중시간 >6	H	9	7	4	1	78	88	-10	100	53	0.6	
	I	7	7	3	2	91		3	9			
	J	9	8	3	3	95		7	49			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
운동시간 <=3.5	H	9	7	4	1	78	78	0	0	0	0.3	2.4
운동시간 <=3.5	I	7	7	3	2	91	93	-2	4	4	0.6	
	J	9	8	3	3	95		2	4			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
집중시간 <=3	A	5	1	10	8	15	22	-7	44	33	0.6	39
	B	2	1	8	9	21		-1	0			
	C	3	2	1	10	29		7	54			
집중시간 >3	D	5	4	9	6	38	45	-7	49	49	0.4	
	E	4	4	5	7	52		7	49			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
공부시간 <=4	B	2	1	8	9	21	25	-4	16	16	0.6	9.6
	C	3	2	1	10	29		4	16			
공부시간 >4	A	5	1	10	8	15	15	0	0	0	0.3	

Decision Tree

최적의 분할 기준 선정

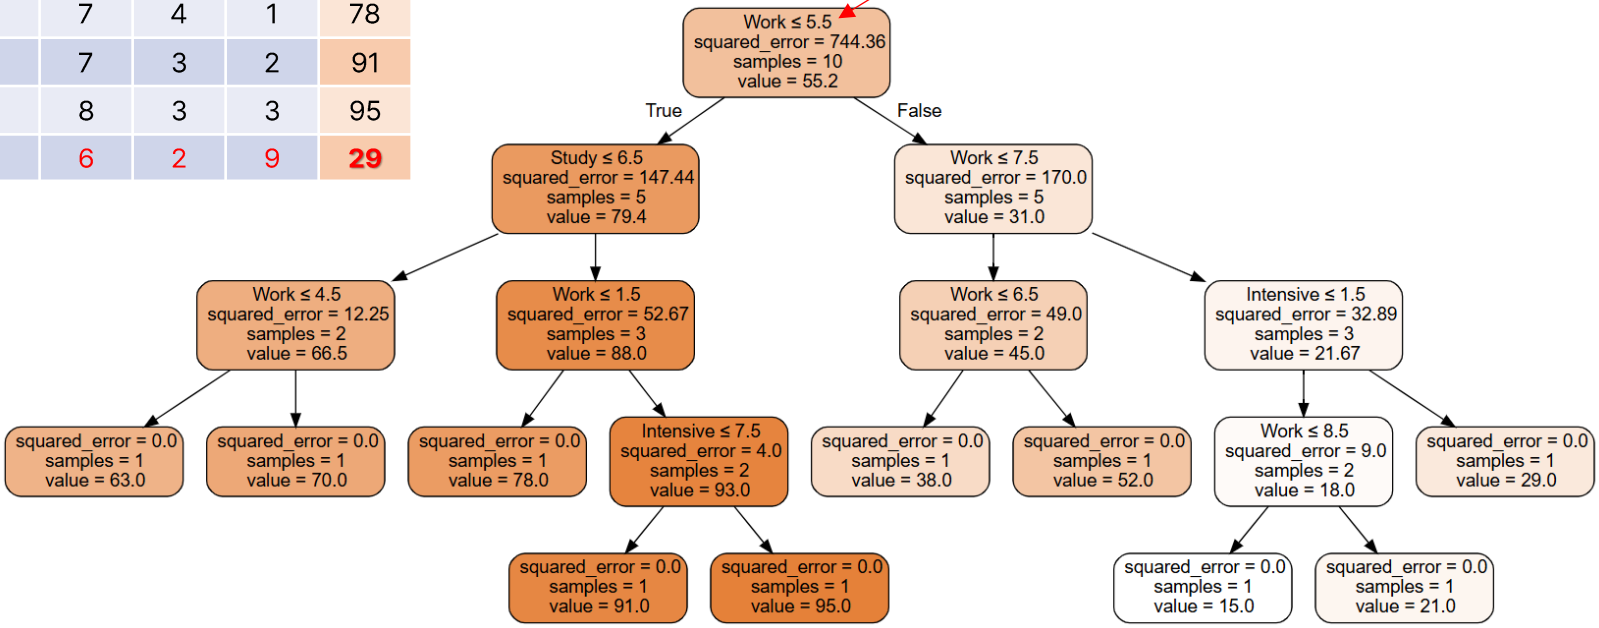
구분	공부 시간	집중 시간	운동 시간	알바 시간	성적
A	5	1	10	8	15
B	2	1	8	9	21
C	3	2	1	10	29
D	5	4	9	6	38
E	4	4	5	7	52
F	5	4	6	4	63
G	6	5	2	5	70
H	9	7	4	1	78
I	7	7	3	2	91
J	9	8	3	3	95
예측용	7	6	2	9	**29**

공부시간	조건	Weighted MSE
2	2.5	614.40
3	3.5	516.35
4	4.5	551.74
5	5.5	210.43
6	6.5	283.29
7	8	499.44
9		

집중시간	조건	Weighted MSE
1	1.5	398.40
2	3	258.89
4	4.5	210.43
5	6	283.29
7	7.5	568.36
8		

운동시간	조건	Weighted MSE
1	1.5	668.09
2	2.5	736.24
3	3.5	572.63
4	4.5	441.60
5	5.5	451.76
6	7	344.81
8	8.5	538.44
9	9.5	564.80
10		

알바시간	조건	Weighted MSE
1	1.5	686.60
2	2.5	529.74
3	3.5	283.29
4	4.5	274.43
5	5.5	**158.72**
6	6.5	295.43
7	7.5	262.44
8	8.5	516.35
9	9.5	668.09
10		



Decision Tree Regression/Classification

회귀 Regression

MSE(mean square error)

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- n : 샘플 개수
- y_i: 실제 값 (target)
- $\hat{y}_i$: 평균 값 (average)

분류 Classification

Gini Impurity (지니 불순도)

$$Gini = 1 - \sum_i p_i^2$$

- p_i : 클래스 i 의 비율

Entropy (엔트로피)

$$Entropy = -\sum_i p_i log p_i$$

- p_i : i 클래스의 비율

- 한 구간 안의 클래스 혼합 정도를 수치화
- 값 ↑ = 여러 클래스가 많이 섞임
- 0 = 한 클래스만 있음 (순수)

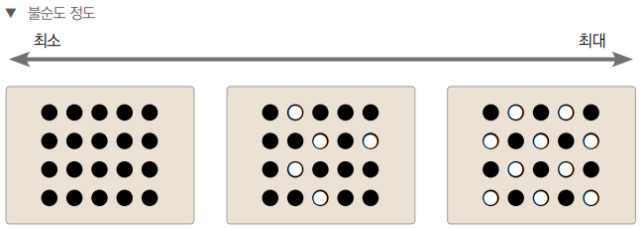
Information Gain (정보이득)

$$IG = MSE_{(before)} - \sum w_i MSE_{i(after)}$$

- 분할 전후 오차/불순도 감소량
- 값이 클수록 좋은 기준

트리 분할 원리

- 기준 및 조건별 오차/불순도 계산
- 정보이득이 가장 큰 기준 선택



성적	등급
15	C
21	C
29	C
38	C
52	B
63	B
70	B
78	B
91	A
95	A

Random Forest : Decision Tree의 무작위 조합



단일 결정나무 → 학습 데이터에 민감, 과적합 발생 위험

랜덤 포레스트의 아이디어

- **무작위(Random)**를 도입해 여러 트리를 학습
  - Bagging (Bootstrap Aggregating): 무작위로 추출된 데이터 샘플로 각 트리를 학습
  - Random Feature Selection: 분할 시 모든 특성을 쓰지 않고, 일부 특성만 무작위 선택
- 이렇게 만들어진 서로 다른 트리들을 결과를 결합**(Ensemble)**하여 해결

⇒ 안정적, 일반화 성능 향상

순서	이름	특성1	특성2	특성3	특성4	성적
1	A	0.36	10.66	-5.31	0	48
2	B	0.81	12.90	-4.72	1	94
3	C	0.53	10.15	-5.19	0	25
4	D	-0.18	11.01	-4.58	0	75
5	E	-0.02	9.72	-4.19	1	61

<원본 데이터>

순서	이름	특성1	특성2	특성4	성적
1	B	0.81	12.90	1	94
2	E	-0.02	9.72	1	61
3	D	-0.18	11.01	0	75
4	B	0.81	12.90	1	94
5	B	0.81	12.90	1	94

<RF Sample>

Random Forest

Bootstrap

Random feature selection

순서	이름	특성1	특성2	특성3	특성4	성적
1	A	0.36	10.66	-5.31	0	48
2	B	0.81	12.90	-4.72	1	94
3	C	0.53	10.15	-5.19	0	25
4	D	-0.18	11.01	-4.58	0	75
5	E	-0.02	9.72	-4.19	1	61

<원본 데이터>

순서	이름	특성1	특성2	특성4	성적
1	B	0.81	12.90	1	94
2	E	-0.02	9.72	1	61
3	D	-0.18	11.01	0	75
4	B	0.81	12.90	1	94
5	B	0.81	12.90	1	94

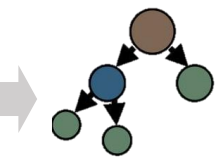
<RF Sample 1>

순서	이름	특성2	특성3	성적
1	A	10.66	-5.31	48
2	D	11.01	-4.58	75
3	C	10.15	-5.19	25
4	D	11.01	-4.58	75
5	A	10.66	-5.31	48

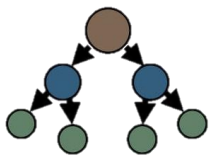
<RF Sample 2>

순서	이름	특성1	특성3	특성4	성적
1	C	0.53	-5.19	0	25
2	C	0.53	-5.19	0	25
3	E	-0.02	-4.19	1	61
4	A	0.36	-5.31	0	48
5	E	-0.02	-4.19	1	61

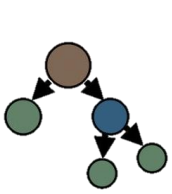
<RF Sample n>



Aggregation



!



Random Forest

Bootstrap

Random feature selection

순서	이름	특성1	특성2	특성3	특성4	성적
1	A	0.36	10.66	-5.31	0	48
2	B	0.81	12.90	-4.72	1	94
3	C	0.53	10.15	-5.19	0	25
4	D	-0.18	11.01	-4.58	0	75
5	E	-0.02	9.72	-4.19	1	61

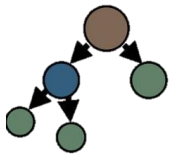
<원본 데이터>

이름	특성1	특성2	특성3	특성4	성적
F	0.50	11.50	-4.80	1	???

<예측 데이터>

순서	이름	특성1	특성2	특성4	성적
1	B	0.81	12.90	1	94
2	E	-0.02	9.72	1	61
3	D	-0.18	11.01	0	75
4	B	0.81	12.90	1	94
5	B	0.81	12.90	1	94

<RF Sample 1>

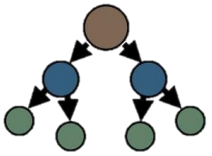


→ 57
(B)

Aggregation

순서	이름	특성2	특성3	성적
1	A	10.66	-5.31	48
2	D	11.01	-4.58	75
3	C	10.15	-5.19	25
4	D	11.01	-4.58	75
5	A	10.66	-5.31	48

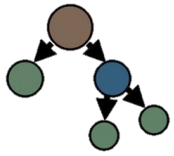
<RF Sample 2>



→ 53
(B)

순서	이름	특성1	특성3	특성4	성적
1	C	0.53	-5.19	0	25
2	C	0.53	-5.19	0	25
3	E	-0.02	-4.19	1	61
4	A	0.36	-5.31	0	48
5	E	-0.02	-4.19	1	61

<RF Sample n>



→ 45
(C)

51.7
(B)

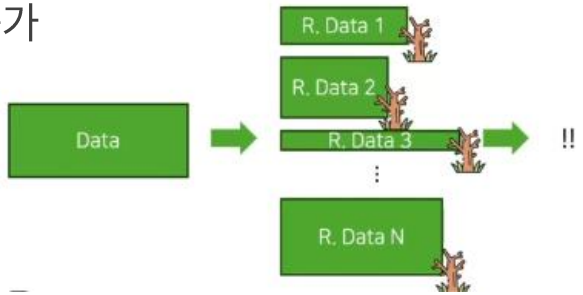
회귀(분류)
⇒ 평균(다수결)

Random Forest 고려사항

Random Forest는 여러 부분에서 Random 특성이 존재하므로 고려할 사항이 있음

몇 개의 트리(=샘플 데이터셋의 수)를 사용할지? (n_estimator)

- 보통 100~500 정도 고려
- 많다면 다양한 모델을 사용하고 안정성이 높아지지만 계산 비용이 증가

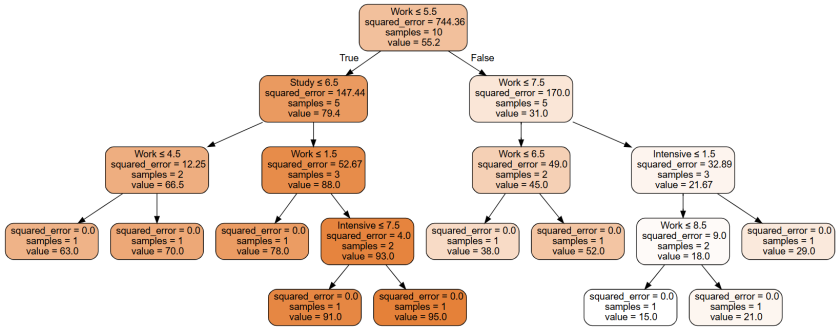


뽑아낼 특성의 수 (max_features)

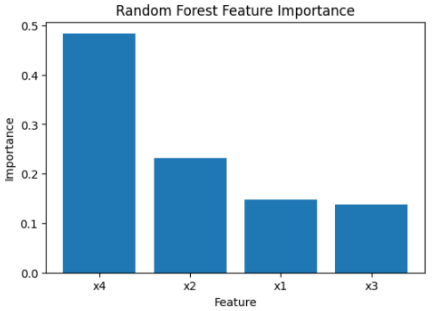
- 데이터셋을 구성할 때, 임의로 뽑아낼 특성의 최대 수
- 보통 √(특성수) 정도를 선택

트리 최대 깊이 (max_depth)

- 하나의 트리가 가지를 뻗어갈 최대 길이
- 깊을 수록 성능이 좋지만 과적합 위험이 있음



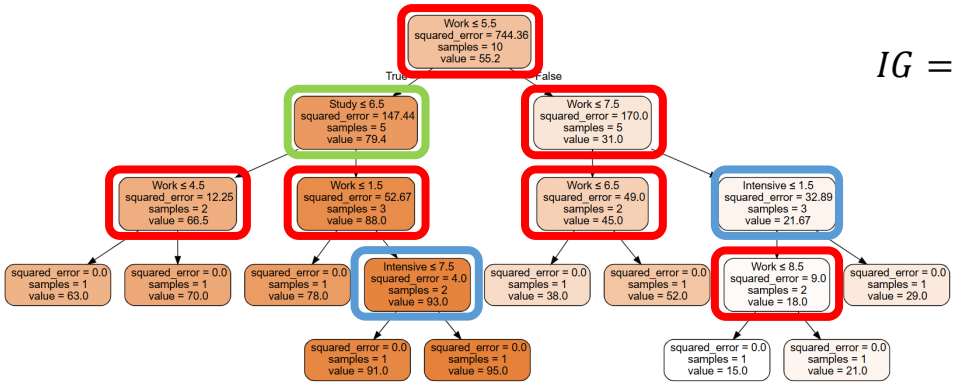
Feature Importance



각 입력특성(x1, x2, x3, ...)가 예측 성능 향상에 얼마나 기여했는지를 나타내는 지표

분할 과정에서 예측 오차를 가장 크게 줄인 중요한 입력 특성(feature)

- 각 분할에서 정보 이득(Information Gain)을 계산
- 해당 feature가 사용된 모든 분할에서 감소량을 노드의 샘플 수 비율을 고려한 가중합으로 누적
- feature 별 기여도를 전체 합이 1이 되도록 정규화



$$IG = \Delta MSE = MSE_{(before)} - \sum w_i MSE_{i(after)}$$

$$contribution = \frac{N_{node}}{N_{total}} \times IG$$

	feature		sample	beforeMSE	weightedMSE	ImformationGain	sample ratio	contribution
1	4	work	10	744	158.5	585.5	1.0	585.5
2	1	study	5	147	18	129	0.5	64.5
3	4	work	5	170	19.4	150.6	0.5	75.3
4	4	work	2	12	0	12	0.2	2.4
5	4	work	3	52	0.8	51.2	0.3	15.36
6	4	work	2	49	0	49	0.2	9.8
7	2	intensive	3	32	1.8	30.2	0.3	9.06
8	2	intensive	2	4	0	4	0.2	0.8
9	4	work	2	9	0	9	0.2	1.8

$$x_1 = \sum contributon\ of\ x_1 = 1572 \Rightarrow \mathbf{0.15}$$

$$x_2 = \sum contributon\ of\ x_2 = 2315 \Rightarrow \mathbf{0.23}$$

$$x_3 = \sum contributon\ of\ x_3 = 1483 \Rightarrow \mathbf{0.14}$$

$$x_4 = \sum contributon\ of\ x_4 = 4827 \Rightarrow \mathbf{0.48}$$