학부 강의용

순환신경망(RNN)의 기초

시퀀스 데이터와 기억을 가진 신경망 · 입력의 순서를 이해하는 신경망

개념 → 구조 → 학습 → 한계 → 응용

개념

1. 왜 RNN이 필요한가?

일반적인 신경망은 입력 간 순서와 시간 관계를 직접 표현하기 어렵다.

문장

단어의 순서에 따라 의미가 달라짐

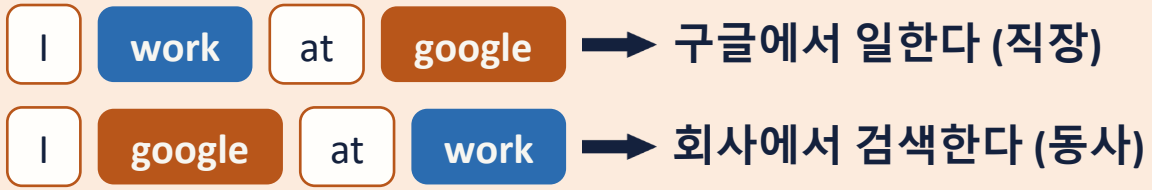
센서 데이터

이전 측정값이 현재 해석에 영향

시계열

과거 정보가 미래 예측의 단서

예: 같은 단어, 다른 순서



개념

2. 시퀀스(Sequence) 데이터란?

시간 또는 순서에 따라 배열된 데이터

텍스트

단어 또는 문자 순서

시계열

온도, 주가, 공정 센서값

음성

시간에 따른 음향 신호

분자 SMILES

원자·기호의 순서

$$x_1 \rightarrow x_2 \rightarrow x_3 \rightarrow \dots \rightarrow x_t$$

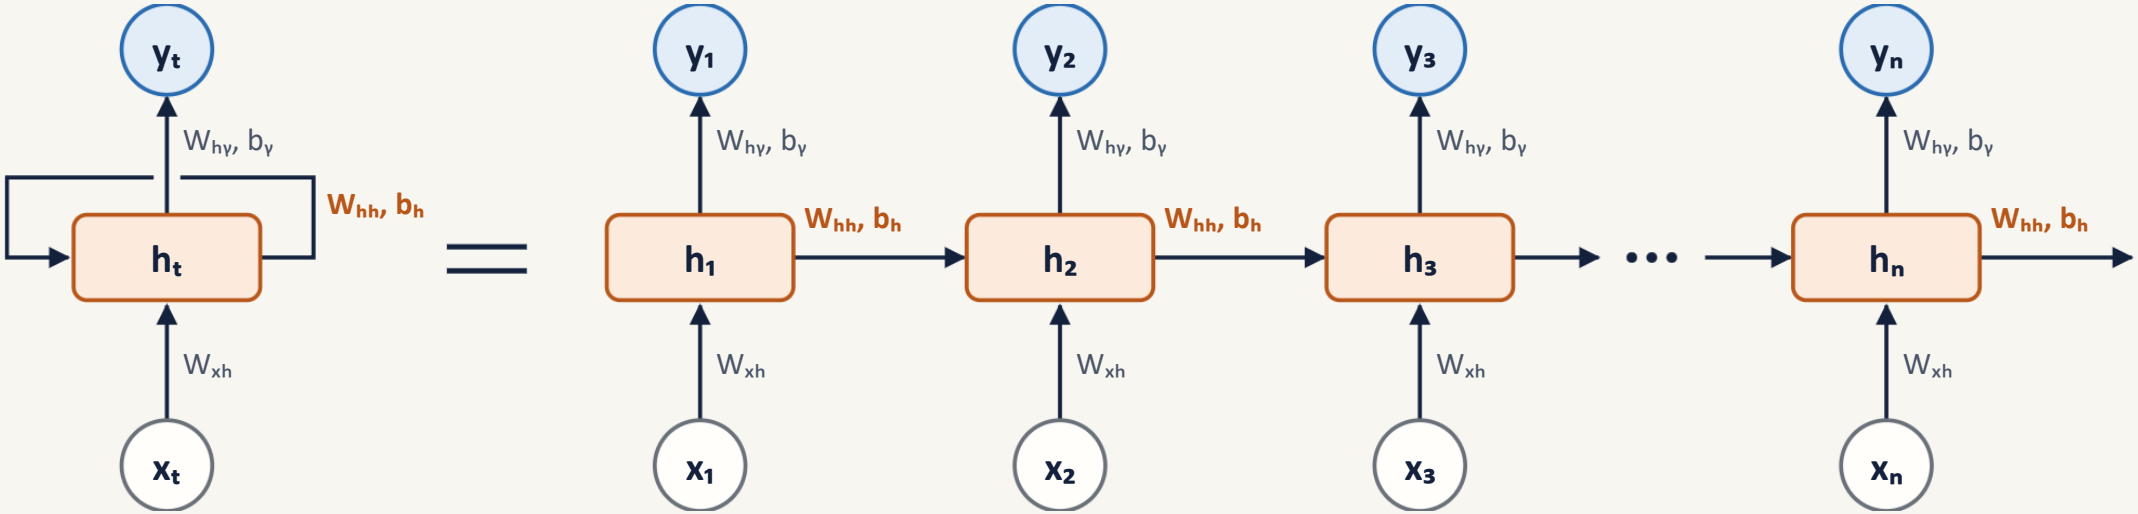
구조

3. RNN의 핵심 아이디어와 시간축 펼치기

현재 입력과 이전 상태를 함께 이용하고, 같은 RNN 셀을 각 시점에서 반복 사용한다.

은닉 상태 (h) = 과거 정보를 요약한 벡터

모든 시점에서 **동일한 가중치 W**를 공유



구조

4. RNN의 계산식

가장 기본적인 Vanilla RNN

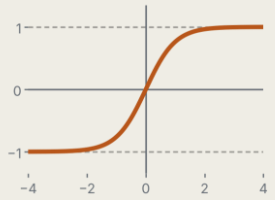
① 은닉 상태

$$h_t = \tanh(W_{xh}\, x_t + W_{hh}\, h_{t-1} + b_h)$$

② 출력

$$y_t = W_{hy}\, h_t + b_y$$

기호	의미
x_t	현재 입력
h_{t-1}	이전 은닉 상태
W	학습 가능한 가중치
b	편향
tanh	비선형 활성화 함수



tanh란?

tanh(x) = (eˣ − e⁻ˣ) / (eˣ + e⁻ˣ)

출력 범위 −1~1, 0 중심 대칭 → 은닉 상태 값이 커지지 않게 눌러 줌

응용

5. RNN의 입력과 출력 형태

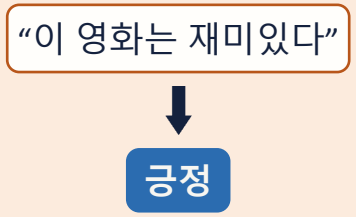
문제에 따라 출력의 개수와 위치가 달라진다.

N → 1

Many-to-One

문장 → 감정 분류 결과 하나

예: 감정 분류

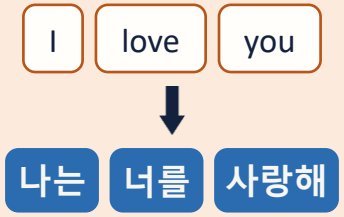


N → M

Many-to-Many

문장 → 다른 언어의 문장

예: 기계 번역

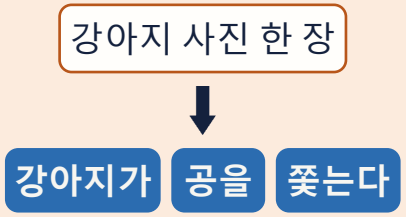


1 → N

One-to-Many

초기 정보 → 연속 출력 생성

예: 이미지 캡션 생성



학습

6. RNN은 어떻게 학습하는가?

BPTT: Backpropagation Through Time

1

순전파

시퀀스를 순서대로 입력하여 예측값 계산

2

손실 계산

예측과 정답의 차이로 손실(loss) 계산

3

시간 역전파

시간축을 거슬러 기울기를 전파

4

가중치 갱신

공유된 가중치를 옵티마이저로 업데이트

순전파 → 손실 계산 → 시간 역전파 → 가중치 갱신

한계

7. 기본 RNN의 한계

긴 시퀀스에서는 오래된 정보를 유지하기 어렵다.

기울기 소실 (Vanishing Gradient)	먼 과거 정보 학습 어려움
기울기 폭주 (Exploding Gradient)	학습이 불안정해짐
장기 의존성 문제	긴 문장·장기 의존성 문제에 취약

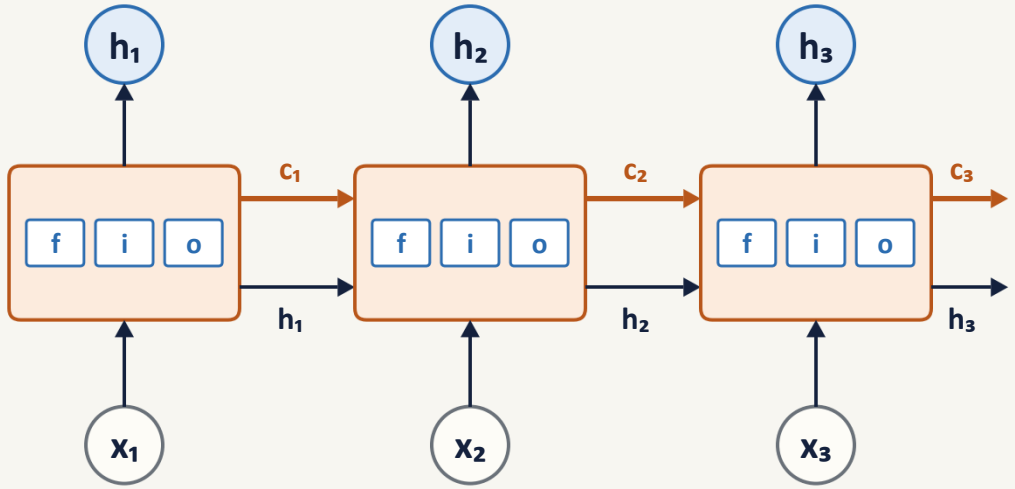
개선 모델: **LSTM**, **GRU** (게이트로 정보 흐름 조절)

개선

8. LSTM과 GRU: 게이트로 기억 조절하기

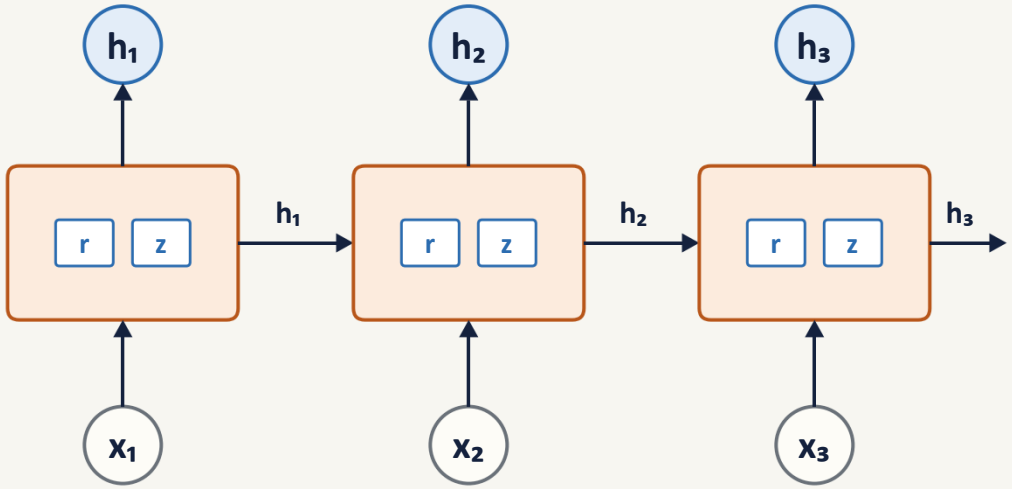
게이트가 어떤 정보를 버리고, 더하고, 내보낼지 학습해 장기 의존성 문제를 완화한다.

LSTM = 셀 상태 **c** + 게이트 3개 (f · i · o)



f 망각 · **i** 입력 · **o** 출력 게이트
c 경로는 덧셈으로 이어져 먼 과거 정보가 잘 보존된다

GRU = 게이트 2개 (r · z), 셀 상태 없이 **h**만 사용



r 리셋 · **z** 업데이트 게이트
LSTM보다 단순해 파라미터가 적고 학습이 빠르다

정리

9. 요약 및 확인 문제

RNN을 이해하기 위한 세 가지 핵심 질문

Q1 RNN이 일반적인 완전연결 신경망과 다른 점은?

Q2 은닉 상태 h_t는 어떤 역할을 하는가?

Q3 RNN의 장기 의존성 문제를 해결하려면?

핵심: 순차 입력 + 은닉 상태 + 시간에 따른 가중치 공유